


Idősor elemzés

Jónás Dániel
Data scientist



Idősor

- Egymást követő állandó intervallumokkal regisztrált adatok
- Az időbeliség fontos
- Például:
 - Időjárás
 - Energiafogyasztás
 - Forgalmi adatok



Modell típusok

Hagyományos statisztikai modellek

- Exponenciális simítás
- Holt-winters-módszer
- ARIMA és társai

Gépi tanulási algoritmusok

- Lineáris modellek
- Fa alapú modellek
- SVM

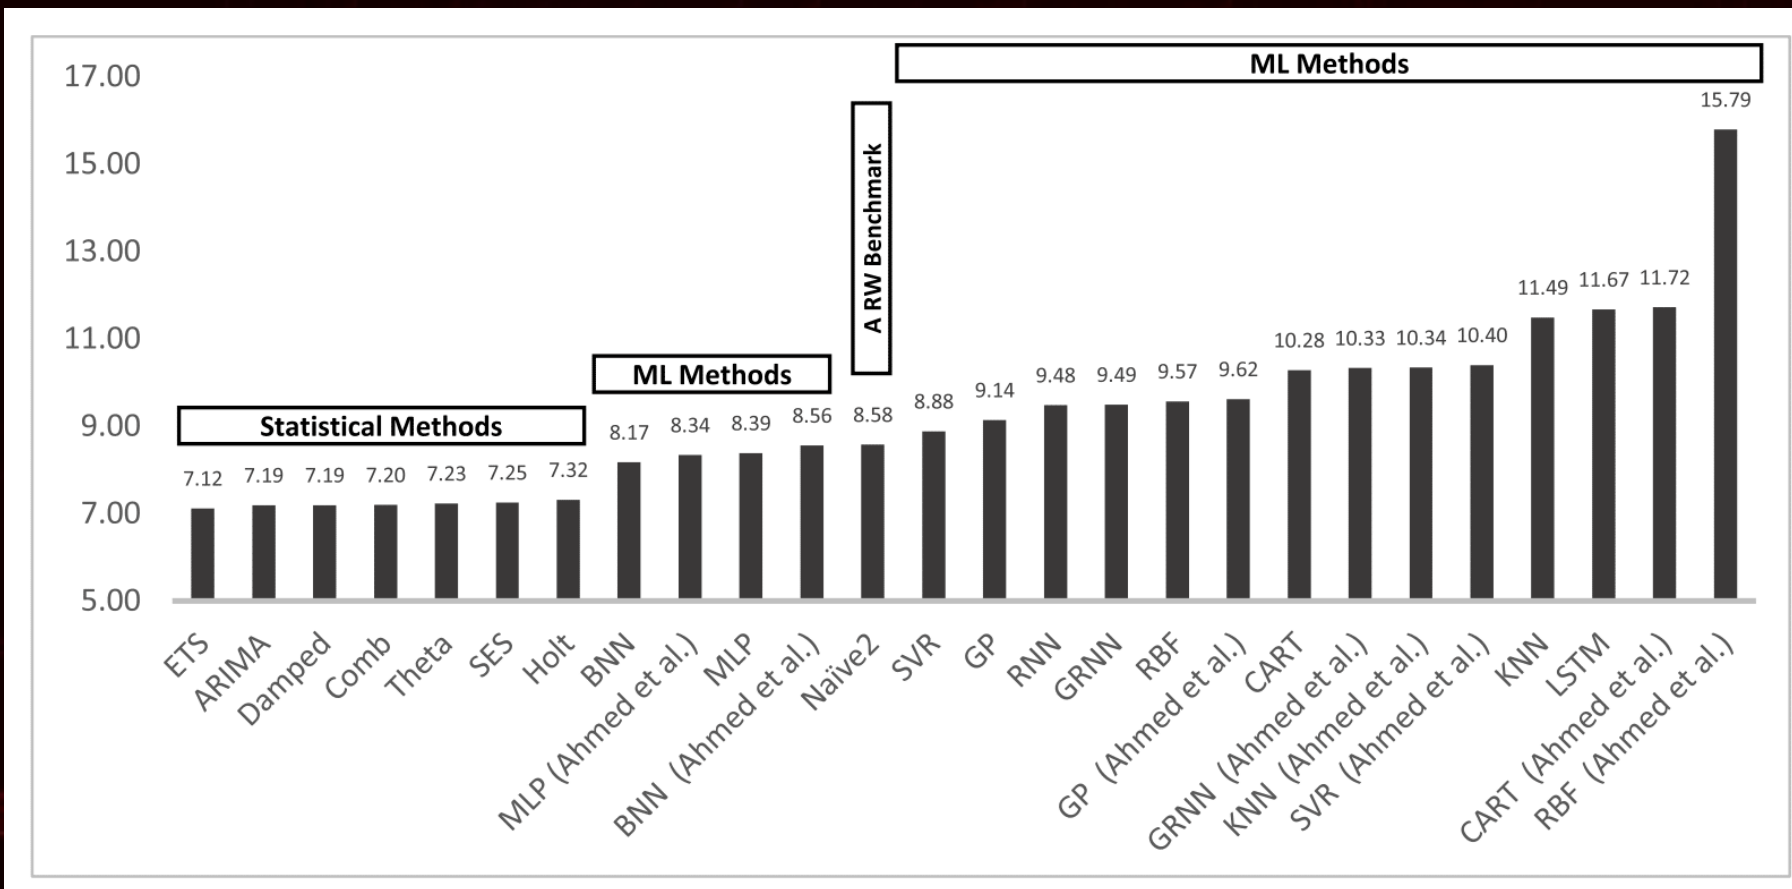
Neurális hálók

- RNN
- LSTM
- GRU
- Transformer

Makridakis competition

- **M4 (2018)**
 - Csak statisztikai módszerek kombinációi ↑
 - Statisztikai módszerek + ML vagy NN ↑
 - Tisztán ML módszerek rosszul teljesítettek ↓
- **M5 (2020)**
 - Tisztán ML módszerek teljesítettek legjobban
 - ML + NN módszerek is megjelentek

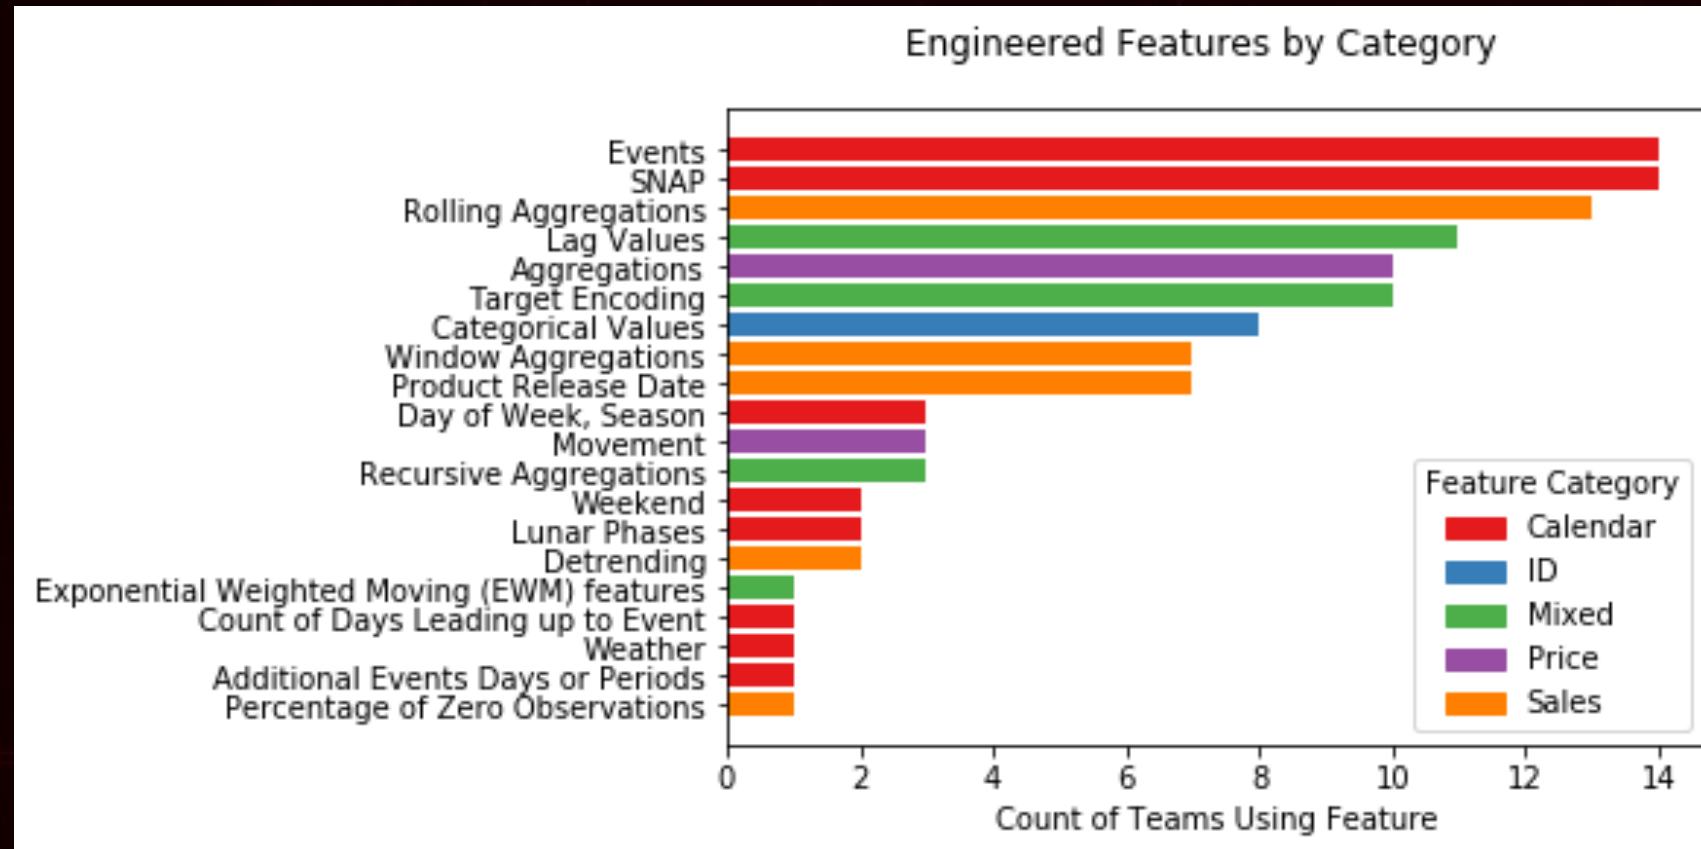
Makridakis competition



Makridakis competition

Team*	Grad. Boosting**	Neural Networks	Proprietary	Statistical Model	Recursive?***
A1	220				Both
A2	10	2 (NBEATS)			R
A4	40				NR
A5	7				R
A18	1				R
U1	126				NR
U2	10		1 (histogram)	1 (SSA)	R
U3	10	3 (Keras - Dense)			R
U4		24 (PyTorch - LSTM)			R
U5	280				NR
U7		2 (Keras - LSTM)			R
U12	9				NR
U18	4	1 (TF Keras - Dense)		1 (Scipy Stats)	Both
U24	10 + 1 (ngboost)	2 (TF Keras - Dense)		3 (Statsmodel QuantReg)	R
U48		1 (PyTorch - Seq2Seq)			R

Makridakis competition



Modell típusok

Hagyományos statisztikai modellek

- Exponenciális simítás
- Holt-winters-módszer
- ARIMA és társai

Gépi tanulási algoritmusok

- Lineáris modellek
- Fa alapú modellek
- SVM


Neurális hálók

- RNN
- LSTM
- GRU
- Transformer

Statisztikai módszerek

Hagyományos statisztikai modellek

- Exponenciális simítás
- Holt-winters-módszer
- ARIMA és társai




Statisztikai módszerek

Hagyományos statisztikai modellek

- Exponenciális simítás
- Holt-winters-módszer
- ARIMA és társai

- Legtöbbször stacionárius idősort feltételeznek
 - Állandó átlag
 - Állandó szórás




Statisztikai módszerek

Hagyományos statisztikai modellek

- Exponenciális simítás
- Holt-winters-módszer
- ARIMA és társai

- Legtöbbször stacionárius idősort feltételeznek
 - Állandó átlag
 - Állandó szórás



Statisztikai módszerek

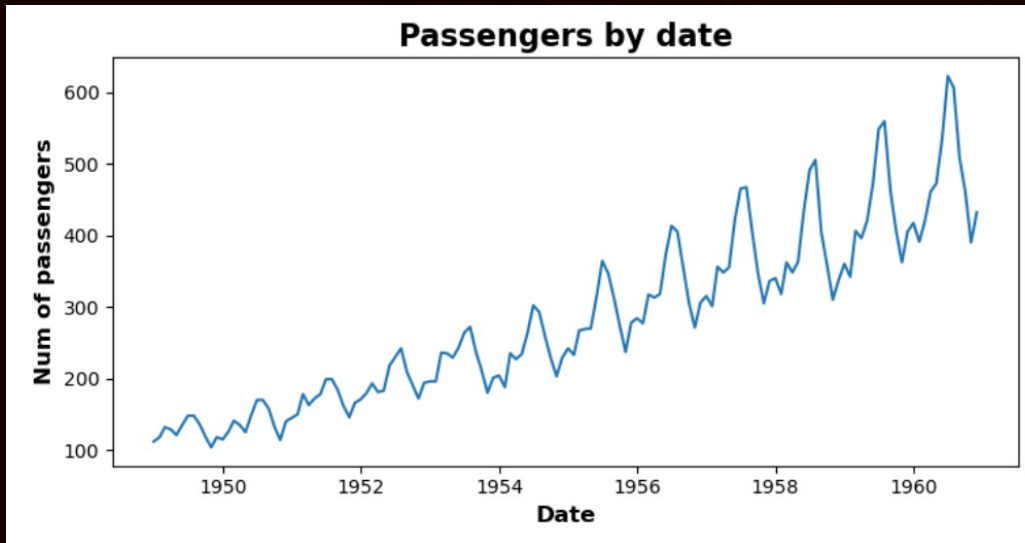
ARIMA (p, d, q)

- AR – autoregressive(p)
- I – integrated (d)
- MA – moving average (q)


$$y'_t = \overset{\text{intercept}}{c} + \underbrace{\varphi_1 y'_{t-1} + \dots + \varphi_p y'_{t-p}}_{\text{lagged values}} + \underbrace{\theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} + \varepsilon_t}_{\text{lagged errors}}$$

differenced time series


Statisztikai módszerek - differenciálás



Statisztikai módszerek - differenciálás



Statisztikai módszerek - differenciálás



Statisztikai módszerek

AR

MA

ARIMA (p, d, q)

- AR – autoregressive(p)
- I – integrated (d)
- MA – moving average (q)

$$y'_t = c + \underbrace{\phi_1 y'_{t-1} + \dots + \phi_p y'_{t-p}}_{\text{lagged values}} + \underbrace{\theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}}_{\text{lagged errors}} + \varepsilon_t$$

Labels in diagram:
 - intercept: c
 - differenced time series: y'_t
 - lagged values: $\phi_1 y'_{t-1} + \dots + \phi_p y'_{t-p}$
 - lagged errors: $\theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$

$$\text{Pred} = b_0 + b_1 x_1 + b_2 x_2 \dots + b_n x_n$$

Simple
Linear
Regression

$$y = b_0 + b_1 x_1$$

Labels in diagram:
 - Constant: b_0
 - Coefficient: b_1

Dependent variable (DV) Independent variable (IV)

Statisztikai módszerek

ARIMA (p, d, q)

- AR – autoregressive(p)
- I – integrated (d)
- MA – moving average (q)

